

1. 주제 선정 배경

본 과제는 보험사 지급심사 담당자를 위한, 유사 분쟁사례 기반 지급판단 보조 AI Agent를 설계 대상으로 선정했다.

지급심사 업무를 주제로 선택한 이유는 세 가지가 있다.

첫째, 지급심사는 보험 가치사슬에서 계약자와 보험사의 이해관계가 직접 충돌하는 지점으로, 규정을 기계적으로 적용하기 어려운 판단이 필요한 업무의 성격이 뚜렷하다. 표준약관과 상품 특별약관만으로 해석되지 않는 애매한 청구 건 (예: 특정 시술이 실손보험 보장 목적에 해당하는지, 후유장애 등급을 어떻게 볼 것인지)이 실무에서 반복적으로 발생하며, 이런 애매함이 바로 분쟁조정 신청으로 이어진다.

둘째, 해외 주요 보험사들이 이미 클레임(보험금 지급) 영역에 에이전틱 AI를 적극적으로 도입하고 있어, 향후 도입 가능성이 막연한 상상이 아니라 산업 전반의 실제 흐름과 맞닿아 있다.

셋째, FSS 분쟁조정사례 201건(그중 보험 권역 160건)이라는 실제 판례 성격의 텍스트 코퍼스를 확보하고 있어, 설계에 그치지 않고 실제로 작동하는 RAG 기반 프로토타입을 시연할 수 있다는 실현 가능성 측면의 이점이 크다.

본 보고서가 다루는 주제 문장은 다음과 같다: "나는 보험 산업의 지급심사 담당자를 위해, 보장범위 해석이 애매한 청구 건에 대한 판단 근거(유사 판례) 제시 문제를 해결하는 AI Agent 를 설계한다."

2. 산업 및 업무 특성 분석

2.1 산업 구조

보험 산업의 핵심 가치사슬은 **상품개발 -> 언더라이팅(가입심사) -> 계약관리 -> 사고 접수(FNOL, First Notice of Loss) -> 손해사정 -> 지급심사 -> 지급/거절 ->(거절/감액 시) 이의 신청 및 분쟁조정 신청의 순서로** 이어진다. 본 과제가 다루는 지급심사는 이 흐름의 후반부에 해당하는 손해사정 결과와 보장 약관을 대조하여 실제 지급 여부와 금액을 확정하는 단계에 해당한다. 만약, 지급심사 결과에 계약자가 불복할 경우 일반적인 경우에 금융감독원 금융분쟁조정위원회 또는 각 회사의 민원 채널을 통한 이의신청 절차로 이어진다.

2.2 주요 이해관계자

- 계약자·피보험자·수익자: 보험금 청구의 주체이자 지급심사 결과의 직접적 이해당사자
- 보험설계사·GA(법인보험대리점): 가입 단계의 판매 채널, 청구 과정에서 계약자를 보조하기도 함
- 손해사정사(자체/위탁): 사고 조사 및 손해액 산정을 담당하며 지급심사의 선행 단계를 수행
- 지급심사 담당자(심사역): 본 Agent의 대상 사용자. 손해사정 결과와 약관을 대조해 지급 여부를 최종 판단
- 특별조사팀(SIU): 보험사기 의심 건을 별도로 조사
- 컴플라이언스·법무팀: 약관 해석의 법적 리스크와 규제 준수를 검토
- 금융감독원(감독당국) 및 금융분쟁조정위원회: 업권 감독과 분쟁조정을 담당하는 외부 기관
- 재보험사: 대형 손해의 경우 지급심사 결과가 재보험 정산에도 영향을 미침

2.3 업무 프로세스 특성: 반복 업무 · 문서중심 업무 · 판단필요 업무

- 반복 업무: 청구서류 접수·등록, 표준화된 소액·정형 청구(예: 정기 통원치료비)의 기계적 심사, 청구인 문의 응대
- 문서중심 업무: 진단서, 입·퇴원확인서, 진료비 영수증, 사고경위서, 약관·특별약관, 과거 유사 청구 이력 등 방대한 비정형·반정형 문서를 대조하는 업무
- 판단필요 업무: 약관상 보장 목적·범위의 해석이 필요한 애매한 청구(신의료기술·미용 목적 병행 시술의 실손 보장 여부, 후유장애 등급 판정 등)에 대한 최종 결정. 단순 규칙 기반 시스템으로 커버되지 않으며, 심사역의 경험과 유사 판례·분쟁조정 사례에 대한 지식에 크게 의존한다.

2.4 주요 데이터

해당 산업은 계약 정보, 청구 서류, 심사·지급 이력, 분쟁조정 사례, 표준약관·법령 데이터를 사용한다.

이 중 본 과제에서는 분쟁조정 사례 데이터를 금융감독원 통합 홈페이지 분쟁조정사례 게시판에서 텍스트 크롤링을 통해 확보했고, 이를 사용한다.

2.5 규제 이슈

- 보험업법 제 95 조의 2(설명 의무 등): 보험회사는 보험계약 체결 시부터 보험금 지급 시까지의 주요 과정을 계약자에게 설명하여야 하며, 보험금을 감액하여 지급하거나 지급하지 않는 경우에는 그 사유를 설명하여야 한다
- 표준약관: 보험금 지급사유, 지급하지 않는 사유(면책조항), 분쟁 발생 시 해석 기준을 제시
- 개인정보보호법 · 신용정보법: 진단서 등 청구서류에는 질병정보 등 민감정보가 포함되므로 처리·보관에 별도의 법적 근거와 통제가 필요
- 보험사기방지 특별법: 사기 의심 청구에 대한 조사·수사 의뢰 절차를 규정하며, 지급심사 판단과 SIU 조사가 연계되는 근거가 됨
- 금융분쟁조정 제도: 금융감독원 금융분쟁조정위원회를 통한 비소송적 분쟁 해결 절차

3. 현재 AI 도입 현황

3.1 Allianz 'Project Nemo' – 에이전틱 AI 기반 클레임 자동화 (해외)

- 해결하는 문제: 자연재해(NatCat) 발생 시 폭증하는 소액·저복잡도 클레임(예: 냉장고 식품 손상 등재산피해) 처리 지연
- 사용 기술: 7 개의 특화된 AI 에이전트(보장확인·기상데이터 대조·사기탐지·감사 등)가 협업하는 멀티에이전트 오케스트레이션 구조. 감사(Audit) 에이전트가 전체 판단 근거를 요약해 사람에게 전달하는 HITL 구조를 갖춘
- 실제 사용자: 호주 Allianz 의 클레임 처리 담당자, 최종 지급 승인은 사람이 수행
- 기대 효과: 2025 년 7 월 호주에서 도입 후, 소액(AUD 500 이하 기준) 클레임 처리 시간이 평균 7 일에서 하루 이내로 단축됨. 담당자는 정형화된 검토 업무에서 벗어나 복잡하거나 민감한 사례에 집중할 수 있게 됨
- 현재 한계: 저복잡도·소액 클레임에 최적화되어 있으며, 복잡한 구조물 손해나 영업중단 손해 등 고난도 판단이 필요한 사례는 여전히 사람이 전담. 서면 데이터가 부족한 사업 초기에는 파일럿 범위를 좁게 시작해야 하는 제

약이 있음

3.2 Lemonade ‘AI Jim’ – 클레임 처리 챗봇 (해외)

- 해결하는 문제: 전통적 보험사의 느린 클레임 처리(수일~수주)로 인한 고객 불만
- 사용 기술: 대화형 AI가 사고 설명(텍스트·영상)을 접수하고, 다수의 이상탐지 알고리즘을 실시간으로 적용해 정책 대조 후 자동 승인
- 실제 사용자: Lemonade 고객(정책 가입자) 및 복잡 건을 넘겨받는 사람 조정자
- 기대 효과: 2025 년 말 기준 최초 사고접수(FNOL)의 96%를 챗봇이 사람 개입 없이 처리하고, 전체 클레임의 55%가 처음부터 끝까지 완전 자동화됨. 단순 사례는 수 초 내 지급까지 완료된 기록도 있음
- 현재 한계: 표준화된 소액·단순 클레임에 자동화가 집중되어 있으며, 복잡하거나 애매한 클레임은 사람 조정자에게 이관됨. 알고리즘 편향 및 규제 대응(설명가능성)이 지속적인 과제로 언급됨

3.3 국내 손해보험사의 AI 심사·사기탐지 도입 (국내)

- 해결하는 문제: 진단서 등 청구서류 심사의 반복 업무 부담과, 조직적·지능화되는 보험사기 탐지의 어려움
- 사용 기술: 삼성화재는 진단서·검사결과지·수술기록지를 자동 분석하는 ‘AI 의료심사’와 머신러닝 기반 장기보험 인수심사 도구 ‘장기 U’를 운영 중이며, DB 손해보험은 사고 접수부터 보상까지 전 과정에 AI가 참여하는 대고객 에이전트를 정식 오픈함. 현대해상은 머신러닝 기반 사기탐지 모델을 운영 중
- 실제 사용자: 각 회사 심사역·손해사정 부서, 그리고 DB 손해보험의 경우 고객이 AI 와 직접 상호작용
- 기대 효과: 현대해상은 사전인지시스템(Hi-FDS)을 통해 한 해 6,201건의 의심 사례를 탐지하고, 이 중 1,012건을 조사해 329건·약 62억 원 규모의 보험사기를 적발한 것으로 보도됨(한국금융신문, 2026.03)
- 현재 한계: 각 사가 개별적으로 자체 시스템을 구축하고 있어 보험업계 전체의 표준화된 접근은 아직 부재하며, 생성형 AI를 악용한 진단서 위·변조 등 새로운 유형의 사기가 함께 증가하고 있어 탐지 기술과 사기 수법간의 ‘군비 경쟁’ 양상이 지속되고 있음

4. 향후 AI Agent 도입 후보 10개

#	후보 Agent	대상 사용자	해결 문제	기대효과	위험도	데이터 접근성
1	언더라이팅 보조 Agent	언더라이터	가입심사 시 정형+비정형 데이터 통합분석 지원	심사시간 단축, 판단편차 감소, 손해율 개선	상 (차별심사·모델 리스크 규제 대응 부담이 실질 장벽)	높음 (내부에 이미 존재, 단 접근 권한 통제 전제)
2	보험사기 탐지 Agent (SIU 보조)	손해사정/SIU 팀	조직적·반복적 사기패턴 탐지	적발 건수·금액 증가, 조사부담 완화	상 (오탐 시 정상계약자 피해, 조사의뢰 법적절차 전제)	낮음 (사기 확정건 자체가 적어 라벨 희소성이 산업 공통 병목)

#	후보 Agent	대상 사용자	해결 문제	기대효과	위험도	데이터 접근성
3	청구서류 (FNOL) 심사 자동화 Agent	청구접수·심사 담당자	서류 수기 대조 반복업무	리드타임 단축, 심사역 여력 확보	중 (오인식 정보가 후속 판단에 전파 가능)	낮음 (민감정보 포함으로 내부 반출·공유 자체가 통제됨)
4	지급판단 보조	지급심사 담당자	보장범위 해석 애매한 청구 판단 근거 부재	근거탐색 시간 단축, 판단 일관성 제고	중 (최종결정권 사람에게 남아 HITL 완충 가능)	높음 (내부 이력 + 금감원 공개 분쟁조정사례 활용 가능)
5	손해사정 자동견적 Agent	손해사정인	사고현장/사진 기반 손해액 산정 지연	조사~견적 리드타임 단축, 인력 부족 완화	중 (자동견적이 관행적으로 채택되면 사실상 결정 대체 효과)	낮음 (사고유형별 라벨링 이미지 데이터 편차가 커 확보 어려움)
6	내부 약관·내규 검색 챗봇	전 임직원(상담원·심사역 등)	약관/내규 방대·분산으로 반복검색 낭비	반복검색 시간 절감, 온보딩 단축	낮음 (참고용, 최종판단 미개입)	중 (문서확보는 쉬우나 개정이력 관리가 번거로움)
7	이의신청/컴플레인 대응 보조 Agent	민원처리 담당자	지급거절 후 이의신청 대응 논리 구성	대응논리 구성 시간 단축, 대응 근거 일관성	중 (표현오류가 민원확산·재분쟁으로 직결, 4번보다 검토부담 큼)	높음 (분쟁조정사례 코퍼스 재사용 가능)
8	계리(보험료 산정) 보조 Agent	계리사	위험 프로파일 기반 적정 보험료 산정	리스크 세분화로 가격 정교화, 손해율 예측 향상	상 (요율산출 감독당국 사전신고·인가가 최대 장벽)	낮음 (계리데이터는 핵심 영업기밀, 사내 접근도 극히 제한)
9	컴플라이언스/규제보고 자동화 Agent	컴플라이언스 팀	감독당국 보고서·내부통제 문서 작성 반복	보고서 작성시간 단축, 보고서 작성 오류 감소	상 (제출문서 오류가 법적책임 직결, 사람 최종검토·서명 필수)	낮음 (내부통제 문서 기밀성 높고 회사마다 표준 달라 범용학습 어려움)
10	고객상담(CS) 챗봇 Agent	콜센터 상담원/고객	반복 문의(청구 절차·보장내용 안내) 응대	상담부담 감소, 대기시간 단축	낮음	중 (상담이력은 있으나 비식별화 처리 전제)

각 Agent 후보들의 사용 기술 및 난이도는 다음과 같다

1	언더라이팅	보조 상	정형(건강검진·병력)+비정형(진료기록 등) 데이터를 통합 분석해야 하고, 결과가 승인/거절/가격에 직결되는 리스크 스코어링이라 정확도 요구 수준이 높음
2	보험사기 탐지	상	조직적·지능화되는 사기 패턴 탐지는 네트워크 분석·이상탐지 등 어려운 ML 문제. 클래스 불균형 (사기 건수가 적음)도 기술적으로 어려움을 더함
3	FNOL 심사 자동화	중	OCR·문서분류는 이미 성숙한 상용 기술이라 새로 개발보다 적용의 문제에 가까움
4	지급판단보조	중	RAG+CRAG+tool-calling ReAct 자체는 이미 검증된 패턴을 조합하는 구조라, 새로운 모델을 학습시키는 것보다는 난이도가 낮다고 봄

5	손해사정 자동견적	상	이미지 기반 손해액 추정은 컴퓨터비전 문제이고, 지역별 시세 데이터 연동까지 필요해 상대적으로 복잡
6	내부 약관 챗봇	중	RAG 기반 시맨틱 검색은 기술적으로는 어렵지 않으나, 문서 최신성 유지 등 운영 이슈가 있어 "하"보다는 "중"으로 판단
7	이의신청 대응보조	중	4번과 거의 같은 기술 스택을 재사용하는 구조라 동일한 근거로 중으로 판단
8	계리 보조	상	통계·계리 모델링은 전통적으로도 어려운 영역이고, 감독당국 신고 수준의 정밀도가 요구됨
9	컴플라이언스 보고 자동화	하~중	문서 생성·반복작업 자동화는 기술적으로 특별히 새롭지 않음
10	CS 챗봇	하~중	FAQ-안내형 챗봇은 이미 상용화가 끝난 커머리티 기술

위 두 표의 정성 비교를 종합해, 각 후보를 네 가지 축으로 정량 스코어링하면 다음과 같다. 임팩트는 해결 문제의 크기와 기대효과를, 실현가능성은 기술 난이도(역산)와 데이터 접근 가능성을 종합한 것이며, 규제·위험 적합성은 위험도를 역산해 감독당국 인가·공정성 검증 부담이 클수록 감점하였다. 판단업무 부합은 규칙으로 대체되지 않는 '판단 보조'에 해당하는 정도로, 본 과제의 핵심 요건을 반영한 축이다. 각 축은 1~5점, 합계 20점 만점이다.

#	후보 Agent	임팩트	실현가능성	규제·위험 적합성	판단업무 부합	합계
4	지급판단 보조	4	5	4	5	18
7	이의신청 대응보조	4	5	3	4	16
1	언더라이팅 보조	5	3	1	5	14
10	CS 챗봇	3	4	5	1	13
6	약관·내규 검색 챗봇	2	4	5	1	12
2	보험사기 탐지(SIU)	5	1	1	4	11
3	FNOL 심사 자동화	3	3	3	2	11
5	손해사정 자동견적	4	2	2	3	11
8	계리 보조	4	1	1	4	10
9	컴플라이언스 보고 자동화	3	3	2	2	10

1위(#4, 18점)와 2위(#7, 16점)는 동일한 데이터·기술 스택을 공유하지만 규제·위험 축에서 갈렸다. #7은 산출물이 소비자에게 직접 전달되는 문서라 표현 오류가 민원 확산·재분쟁으로 직결되는 반면, #4는 결과물이 심사역 내부 참고자료에 머문다. 임팩트 최고점(5점)을 받은 #1·#2는 결과가 가입·가격·보상에 직결되는 결정형 업무라 규제·위험 축에서 1점에 그쳐 종합 순위가 밀렸다. 필요성이 아니라 도입 장벽이 우선순위를 가른 것으로, 이 배제 논리는 5장에서 상술한다.

5. MVP Agent 선정 이유

10개의 후보 중 4번 지급판단보조 Agent를 MVP Agent로 선정했다. 실제 산업에서의 필요성과 도입장벽을 우선순위로 두고 판단했다.

1,2,5,8번 후보의 경우 산업에서의 필요성은 상당히 높지만, 결과가 가입·가격·보상액에 직접 영향을 주는 결정형 업무라 공정성 검증, 감독당국 사전 인가 절차, 모델 리스크 관리체계가 선행돼야 한다. 사기탐지는 라벨 희소성, 계리는 영업기밀성 때문에 데이터 확보도 산업 내부에서조차 어렵다. 필요성은 통과하지만 도입 장벽이 높다.

3,9번 후보는 반복문서 업무 자동화이지만, 서류 대조 수준에 머물기 때문에 판단이 필요한 업무 라는 핵심 요건에 약하다.

6,10번 역시 판단에 관여하지 않기 때문에 핵심 요건에 약하다.

7번이 데이터와 기술 기반을 공유하는 가장 근접한 후보이지만, 소비자에게 직접 전달되는 문서를 다뤄 표현오류가 민원확산·재분쟁으로 직결될 가능성이 높아져 위험 부담이 있다.

반면 4번 후보의 경우에, 지급심사는 케이스마다 정황이 달라 규칙 기반으로 대체되지 않는 판단 업무다. 또한, 최종 결정권을 심사역에게 남기고 Agent는 참고 판례 제시까지만 수행하도록 설계해, 언더라이팅·계리 Agent처럼 Agent가 결정을 내리는 구조의 공정성 리스크를 원천적으로 피한다. 그리고 결과물이 소비자에게 노출되지 않고 심사역 내부 참고자료로 머물러, 같은 판단보조 그룹 안에서도 위험도를 낮출 수 있다.

6. Agent 사용자 시나리오

본 보고서에서 설계하는 MVP Agent의 이름은 **ClaimPrecedent**로 명명한다. 청구(Claim)에 대해 판례(Precedent)를 제시한다는 의미이며, 이하의 설계·구현·실측 내용은 모두 ClaimPrecedent를 대상으로 한다.

6.1 Agent 사용자

해당 Agent의 사용자는 보험사 지급심사 담당자(심사역)로, 특히 실손 보험 · 질병상해간병 보험 등 보장범위 해석에 애매함이 있는 케이스를 다루는 인력이 사용한다.

6.2 사용 시나리오

1. 심사역이 애매한 청구 건을 시스템에 입력한다
2. Agent가 여러 tool(다음 장에 자세히 설명)을 스스로 판단해 호출 순서와 횟수를 결정하며 판단 근거를 구성한다. 근거가 불충분하면 검색어를 스스로 재구성해 재검색한다.
3. Agent가 최종 결정을 통해 참고의견(승인/반려/추가검토)과 근거강도를 제출한다.
4. 근거가 약하거나 결과가 소비자에게 불리한 방향이거나, 추천이 '추가검토 필요'이거나, 웹검색 결과를 사용한 경우, 사람 승인 게이트(HITL)에서 자동으로 멈춘다. 이 조건에 모두 해당하지 않을 때만(근거강도 충분 + APPROVE + 웹검색 미사용) 자동 통과된다.
5. 심사역이 최종판단을 내리고, 그 결과가 로그로 남는다.

6.3 입력과 출력

입력: 케이스 요약(질병/치료명, 상품유형, 쟁점 텍스트), 자유서술 질의

출력: 유사 판례 리스트(사례번호·핵심쟁점 요약·유사도), 판단근거 요약, 참고의견, 근거강도 표시, 외부참고자료 (웹검색, 있을 경우 내부판례와 구분 표시), HITL 필요 여부 플래그

7. 필요한 데이터와 도구

7.1 필요 데이터

금융 분쟁조정사례 비정형 텍스트. 출처는 금융감독원 통합 홈페이지 분쟁조정사례 게시판(fss.or.kr)이고, 형식은 HTML구조에서 텍스트 크롤링을 통해 총 201건의 데이터를 수집했다.

7.2 Tool

Tool	역할
vector_search_tool	PostgreSQL + pgvector 기반 유사 분쟁사례 검색 (LLM이 호출 시점·검색어·횟수를 자율적으로 결정)
relevance_reranker	검색 결과의 실제 관련성 재검증 및 필터링(CRAG). 이 tool을 통과하지 못한 case_id는 최종 인용에 쓸 수 없음
case_id_validator	인용하려는 case_id가 (1)실제 검색됐는지 (2)relevance_reranker를 통과했는지 이중 검증 (환각 방지 + CRAG 우회 방지)
evidence_strength_scorer	근거강도 산정 및 HITL 트리거 여부 판정
web_search_tool	fss.or.kr/law.go.kr/kiri.or.kr 도메인 제한 웹검색. 결과는 외부참고자료로만 취급, 근거강도 미반영, 사용 시 HITL 강제
hitl_interrupt (LangGraph)	승인 게이트 발동 및 심사역 검토 대기 상태 관리. LLM 재량 밖의 결정론적 노드
audit_logger	입력·출력·승인여부·채택률을 감사추적용으로 기록. LLM 재량밖의 결정론적 노드

7.3 외부 도구 또는 API

LLM API (OpenAI gpt-4o-mini, function-calling): 쟁점 이해, tool 호출 판단, 근거 요약 생성. 관련성 재검증 (relevance_reranker) 내부에서도 별도로 호출되어 후보 사례의 관련성을 판정함

임베딩 API (text-embedding-3-small): 분쟁사례 사전 벡터화(적재 시) 및 심사역 질의(검색어)의 실시간 벡터화 (검색 시) 양쪽에 사용됨

PostgreSQL + pgvector: 벡터 검색 및 사례 메타데이터 저장뿐 아니라, 감사로그 저장에도 동일 DB가 사용됨

LangGraph (StateGraph + interrupt()): 오케스트레이션 및 HITL 제어

Serper API (Google Search): web_search_tool을 통해 금융감독원(fss.or.kr), 국가법령정보센터(law.go.kr), 보험연구원(kiri.or.kr) 등 신뢰 도메인으로 검색 범위를 제한한 웹검색을 수행. 내부 코퍼스만으로 부족할 때 보조적으로 사용하며, 결과는 근거강도 산정에 포함되지 않음

8. 기술 아키텍처


8.1 업무 흐름

현 구조는 두 영역으로 나뉜다.

첫째, **react 영역**은 LLM(gpt-4o-mini, function-calling)이 tool 중 무엇을 언제 얼마나 호출할지 스스로 판단하는 자율 ReAct 루프다. 1차 검색 결과의 관련성이 낮으면 LLM이 검색어 자체를 재구성해 다시 검색할 수 있으며, 판단이 끝나면 `finalize_opinion`을 호출해 쟁점·참고의견·추천·인용사례를 제출하고 루프를 종료한다(최대 8회 tool 호출 왕복 내에서 종료되지 않으면 '판단 불가, 사람 판단 필요'로 안전하게 종료).

둘째, **가드레일 영역**은 risk(위험도 판정) → hitl(interrupt 승인게이트) → log(감사로그 저장) 3개 노드로, react 영역과 달리 LLM이 실행 여부를 선택할 수 없는 고정된 노드다. 근거강도·추천·외부참고자료 사용 여부에 따라 필요할 경우 반드시 사람 승인을 거치도록 그래프 레벨에서 강제한다.

인용된 사례에 대해서는 LLM의 자기 신고를 그대로 신뢰하지 않는다. react 루프 종료 시 서버 측에서 (1) 실제로 이번 세션에서 검색된 사례인지, (2) `relevance_reranker`를 실제로 통과한 사례인지를 독립적으로 재검증하며, 두 조건 중 하나라도 충족하지 못하면 해당 인용은 자동 제거되고 경고 문구가 추가되며 추천은 강제로 '추가 검토 필요'로 전환된다.



8.2 RAG 활용 여부


RAG는 본 Agent의 핵심 구성요소다. 201건(그중 보험 관련 160건)을 코퍼스로 하는 RAG에 CRAG 방식의 관련성 재검증(검색결과가 실제로 관련 있는지 필터링한 뒤, 부족하면 재검색)을 결합하였다. Self-RAG의 전체 루프나 다중 에이전트 협업 구조는 본 과제 스코프에서 제외하고, 향후 확장 과제로 남겨둔다.

내부 코퍼스만으로 판단 근거가 부족한 경우를 보완하기 위해 신뢰 도메인 제한 웹검색(web_search_tool)을 추가로 도입하였다. 다만 웹검색 결과는 내부 판례와 동일한 신뢰도로 취급하지 않는다 — (1) '외부참고자료'로 명확히 구분 표시하고, (2) 근거강도(evidence_strength) 산정에서 제외하며, (3) 사용된 모든 케이스는 근거강도·추천과 무관하게 반드시 HITL을 거치도록 하였다.

8.3 시스템 아키텍처

시스템은 UI/애플리케이션 – 오케스트레이션(LangGraph) – 모델·도구 – 데이터·저장 – 거버넌스의 5개 계층으

로 구성된다. 오케스트레이션 계층은 react(자율 tool-calling 루프)-risk-hitl-log 4개 노드로 이루어지며, 모델·도구 계층에는 LLM API(gpt-4o-mini, function-calling)와 임베딩 API 외에 5개의 tool(vector_search_tool, relevance_reranker, case_id_validator, evidence_strength_scorer, web_search_tool)이 포함된다. 데이터·저장 계층에는 pgvector 기반 사례 코퍼스와 감사로그 테이블에 더해, 웹검색 결과 기록을 위한 external_references 컬럼이 추가되었다.



9. Human-in-the-loop 설계

LangGraph의 interrupt() 및 StateGraph를 이용해 HITL을 구현한다. 아래 조건 중 하나라도 해당하면 Agent는 최종 답을 확정하지 않고 심사역의 승인을 기다린다.

- 유사 판례가 없거나 관련성이 낮을 때
- 참고의견이 '반려'(소비자 불리) 방향일 때
- 근거강도 점수가 임계치 이하일 때
- AI 추천이 '추가검토 필요'(ADDITIONAL_REVIEW_NEEDED)인 경우 — 근거강도와 무관하게 강제. 프로토타입 실제 실행 검증 과정에서, 근거강도 조건만으로는 AI 스스로 결론에 확신이 없는 케이스가 걸러지지 않는 논리 공백이 발견되어 추가하였다.
- 웹검색(web_search_tool) 결과가 하나라도 사용된 경우 — 외부참고자료는 내부 판례 대비 검증 신뢰도가 낮다고 판단하여 무조건 HITL을 거치도록 함.

HITL의 멈춤-재개는 interrupt() 함수와 MemorySaver checkpointer로 구현된다. hitl_node에서 interrupt()가 호출되면 그래프 실행이 그 지점에서 정지하고, 그 순간의 상태(추출된 쟁점, 인용 사례, 근거강도, HITL 발동 사유 등)를 checkpointer가 보존한다. 심사역이 승인 여부(ACCEPT/MODIFY/REJECT)를 입력하면 보존된 상태 그대로 그래프가 재개되어 로그 저장 단계로 이어진다.

Agent가 산출하는 결과는 시스템·보고서 양쪽에서 항상 참고자료로 명시되며, 최종 결정이 아니라는 점을 사용자 인터페이스 문구에도 반영한다. 위 조건에 모두 해당하지 않는 경우(근거강도 HIGH + 추천 APPROVE + 웹검색 미사용)에 한해 HITL 없이 자동으로 참고의견이 제시된다.

10. Agent 데모 모델

본 Agent는 OCI Compute VM(Oracle Linux 8) 환경에 PostgreSQL 16 + pgvector, LangGraph 기반 Agent 코드와 함께 배포되어 end-to-end 동작을 확인하였다.

10.1 실행 결과

- 심사역 입력: 실손보험 가입자가 A 시술을 받고 진료비 청구. 치료 목적과 미용 목적이 혼재되어 보이는데, 유사 분쟁조정사례가 있는지 확인해줘.

Agent는 react 루프 안에서 다음 순서로 tool을 자율적으로 호출하였다 (사전에 정해진 순서가 아니라 LLM 이 매단계 다음 행동을 결정한 결과):

- ① vector_search_tool 호출 → 5 건 검색됨: FSS-0014, FSS-0056, FSS-0026, FSS-0201, FSS-0150
- ② relevance_reranker 호출 (5 건 전체를 candidate로 제시) → 관련 있다고 판단된 3 건 반환: FSS0014, FSS-0056, FSS-0201
- ③ case_id_validator 호출 → 3 건 모두 유효 확인 (환각 없음, CRAG 우회 없음)
- ④ evidence_strength_scorer 호출 → HIGH (관련 사례 3 건, 임계치 3 건 이상)
- ⑤ finalize_opinion 호출 → 아래 참고의견과 함께 루프 종료

- Agent 참고의견: 실손보험에서 치료 목적과 미용 목적이 혼재된 경우, 보험금 지급 여부는 해당 치료가 보험 약관에서 정한 보장 범위에 포함되는지에 따라 달라질 수 있습니다. FSS-0014(치료 목적 보조기 구입비용 부지급 사례), FSS0056(압박고정용 재료대 부지급 사례), FSS-0201(의학적 증거 미비로 인한 비급여 치료 부지급 사례)이 참고가 될 수 있습니다. (참고자료이며 최종 결정이 아닙니다)

추천은 ADDITIONAL_REVIEW_NEEDED였다. 근거강도는 HIGH였음에도, '추천이 추가검토 필요한 경우 근거강도와 무관하게 HITL을 강제'하는 규칙(9장)에 따라 HITL 승인 게이트가 발동하였고, 콘솔에서 심사역의 ACCEPT 입력을 받아 그래프가 재개되었다. 이후 전체 과정(입력, 쟁점, 검색사례, 인용사례, 근거강도, 추천, HITL 여부, 심사역 결정)이 agent_audit_log 테이블에 감사로그로 저장되었다.

10.2 추가 실행 사례 — 오류 방어와 기권

① 오류 방어(HITL의 실질 작동): '음주운전 면책 조항 적용 여부가 쟁점인 상해보험 청구 건' 입력에서, Agent는 검색 상위 5건 중 무관 사례 4건을 relevance_reranker에서 정확히 탈락시켰으나, 키워드('음주운전')만 유사한 구상권 분쟁 사례(FSS-0182) 1건을 통과시켜 인용하였다. 해당 사례의 쟁점(사고부담금 구상의 타당성)은 본 청구 건의 쟁점(면책조항 해석)과 상이한, 표면적 유사성이 CRAG를 통과한 잔여 오류였다. 이 건은 설계된 조건에 따라 HITL 승인 게이트에서 정지하였고, 심사역이 인용 판례 원문과 쟁점을 대조한 뒤 REJECT로 기각하였으며 기각 사실이 감사로그에 기록되었다. 자동화 파이프라인이 걸러내지 못한 오류를 최종 결정권을 가진 사람이 차단하는, HITL 설계의 존재 이유를 보여주는 사례다.

② 정직한 기권(억지 답변 방지): 코퍼스에 관련 사례가 존재하지 않는 쟁점(도수치료·신의료기술·정신질환·태아보험)의 질의에서, Agent는 검색어를 재구성한 재검색을 반복한 뒤 '판단 루프가 최대 반복 횟수 내에 결론을 내지 못했습니다. 사람의 직접 판단이 필요합니다.'를 출력하고 근거강도 LOW로 종료하였다. 실측 표본 내에서 근거 없는 억지 인용은 0건으로, 11장의 표본 편향 통제 방안이 실제로 작동함을 확인하였다. 다만 기권까지 최대 반복 횟수(8회)를 모두 소진하는 비효율이 확인되어 '조기 기권' 규칙의 추가가 개선 과제로 도출되었고, 해당 규칙은 이후 구현·재실측하였다(12.6 참조).

10.3 실패 시나리오 및 대응

- 판례 부족: 코퍼스에 유사 사례가 전혀 없는 경우 → Agent는 억지 답변 대신 '판례 부족, 사람 판단 필요'를 명시적으로 출력하고 HITL 로 전환
- 환각 인용 시도: LLM 이 실제로 검색되지 않은 사례 ID를 생성하려는 경우 → case_id_validator의 서버 측 독립 재검증이 이를 걸러내고 해당 인용을 자동 제거, 경고 문구 추가 후 재검토 요청
- CRAG 우회 시도: LLM 이 relevance_reranker를 통과하지 않은(또는 애초에 후보로 넣지 않은) case_id를 finalize에서 인용하려는 경우 → case_id_validator의 독립 재검증에서 걸러지고, 해당 인용이 자동 제거되며 추천이 '추가검토 필요'로 전환됨 (개발 중 실제 프로토타입 실행에서 발견 및 수정된 패턴)
- 쟁점 오추출: react 루프 초반에 쟁점을 잘못 파악해 무관한 사례가 검색되는 경우 → relevance_reranker 단계의 관련성 재검증에서 낮은 점수로 필터링되어 '관련 사례 없음'으로 처리
- 악의적/모호한 입력: 심사역이 아닌 사용자가 시스템에 접근하려는 시도 → 접근권한 통제(최소 권한 원칙)로 차단

11. 위험 요소 및 통제 방안

위험 요소	설명	통제 방안
환각	존재하지 않는 판례를 인용할 위험	실제 검색된 사례 ID만 인용하도록 제약. case_id_validator가 (1)실제 검색 여부 (2)relevance_reranker 통과 여부를 이중 검증하며, LLM의 자기신고를 그대로 믿지 않고 서버 측이 독립적으로 재검증
개인정보	분쟁사례 본문에 질병명 등 민감 정보가 포함될 수 있음	비식별화 여부 확인, 접근권한 통제(최소 권한 원칙 적용)
표본 편향	쟁점 유형별 표본 수 편차가 있어 커버리지가 제한적	판례가 부족한 경우 억지로 답변을 생성하지 않고 '판례 부족, 사람 판단 필요'로 명시적으로 표기
책임소재	AI 판단을 그대로 수용할 경우 책임 소재가 불분명해질 위험	Agent는 참고자료 제공까지만 수행하며, 최종 지급결정 책임은 심사역·보험사에 있음을 시스템 및 문서에 명시
보안	API 키 등 민감정보의 하드코딩 및 벡터 DB 접근 통제 미비	API 키는 환경변수로 관리, 벡터 DB 접근권한 통제 적용
외부 정보 신뢰도	웹검색 결과는 공식 판례 대비 검증 신뢰도가 낮고, 왜곡되거나 시의성이 맞지 않을 수 있음	검색 도메인을 fss.or.kr/law.go.kr/kiri.or.kr로 제한. 근거강도 산정에서 제외. 사용 시 근거강도·추천과 무관하게 무조건 HITL. 내부판례/외부자료를 명확히 구분 표기
HITL 회피 논리공백	근거강도만으로 HITL을 판단할 경우, AI 자신의 결론이 불확실(추가검토 필요)해도 근거 개수가 많 게 HITL 강제 실행으면 자동승인될 수 있음	recommendation이 ADDITIONAL_REVIEW_NEEDED인 경우 근거강도와 무관하

12. 평가 지표 및 실측 결과

12.1 평가 지표 정의

본 Agent의 성능은 다음 6개 지표로 평가한다. 정확도를 제외한 5개 지표는 agent_audit_log 테이블에 자동 적재되는 실행 로그를 SQL로 집계하여 산출하며, 정확도는 인용 판례의 관련성을 수동 판정한 근사치로 산출한다.

지표	정의 및 산출 방식	측정 근거(로그 컬럼)
정확도 (Precision, 표본 수동 평가)	판례를 인용한 케이스 중 인용 판례가 실제 쟁점과 관련 있는 케이스의 비율. 인용 사례 원문(쟁점·처리결과)과 대조하여 수동 판정	filtered_case_ids + 수동 판정
환각 rate	인용 시도된 전체 case_id 중 case_id_validator가 반려(미검색 또는 CRAG 미통과)한 비율	hallucinated_case_ids, not_reranked_case_ids / cited_case_count
Task 달성률	최대 반복 횟수(8회) 내에 finalize_opinion으로 정상 종료한 실행의 비율	loop_completed
Avg latency	첫 LLM 응답까지의 시간 및 react 루프 전체 처리 시간(초). HITL 대기시간 미포함	first_response_latency_sec, react_latency_sec
Token cost	케이스당 평균 토큰 사용량 × 모델 단가(gpt-4o-mini, text-embedding-3-small)로 산출한 예상 비용	토큰 컬럼 3종, estimated_cost_usd
Human override	HITL에서 심사역이 검토한 건 중 AI 초안을 수정(MODIFY) 또는 기각(REJECT)한 비율	human_decision

12.2 측정 환경 및 방법

측정은 OCI Compute VM(Oracle Linux 8, PostgreSQL 16 + pgvector) 환경에서 수행하였다. 실손보험·후유장해·면책조항·고지의무 등 쟁점 유형을 분산시킨 테스트 질의 15건의 배치 실행을 포함해 총 40회의 end-to-end 실행 로그를 집계 대상으로 하였다. HITL 승인 판정(ACCEPT/MODIFY/REJECT)은 실제 심사역이 아닌 작성자 본인이 인용 판례 원문과 대조하여 수행하였으므로, 본 결과는 자체 테스트 기준의 참고치이며 실제 심사역 대상 파일럿에서의 재측정이 필요하다.

12.3 실측 결과

지표	실측치	비고
정확도 (Precision)	0.80 (인용 케이스 10건 중 관련 8건)	불일치 2건은 키워드는 유사하나 쟁점이 다른 사례(구상권 vs 면책조항 등). 정식 골드셋 기반 정확도는 향후 과제
환각 rate	0% (인용 시도 30건 중 반려 0건)	표본 내 환각 인용 미발생. validator의 차단 능력 자체는 개발 단계에서 별도 확인(10.3 참조)
Task 달성률	82.6% (19/23)	미완료 4건은 모두 코퍼스에 관련 사례가 0건인 쟁점(도수치료·신의료기술·정신질환·태아보험)
Avg latency	첫 응답 1.37초 / 루프 전체 평균 10.7초 (p50 10.5초, p95 15.2초)	p95 상위 케이스는 모두 루프 미완료 건(재검색 반복)
Token cost	케이스당 평균 약 \$0.0018 (입력 10,676	루프 미완료 건은 재검색 반복으로 평

	/ 출력 387 / 임베딩 40 토큰)	균 대비 약 2배의 입력 토큰 소모
Human override	7.5% (검토 40건 중 MODIFY/REJECT 3건)	HITL 개입률 97.5%. 해석은 12.4 참조

12.4 결과 해석

첫째, HITL 개입률 97.5%는 시스템 결함이 아니라 보수적 승인 게이트가 의도대로 작동한 결과다. 본 Agent의 대상 업무 자체가 보장범위 해석이 애매한 청구 건이며, 테스트 질의 역시 전건 애매한 쟁점으로 구성하였다. 이러한 입력에서 LLM은 대부분 '추가검토 필요'를 추천하였고, 해당 추천은 근거강도와 무관하게 HITL을 강제하도록 설계되어 있다(9장). 따라서 본 Agent의 효율 기여는 자동 승인율이 아니라 근거 탐색 시간 단축에 있다. 심사역이 수작업으로 분쟁조정사례를 탐색하는 대신, 케이스당 평균 약 10초에 관련 판례 후보와 요약을 제공받는다.

둘째, Task 달성률 82.6%의 미달성 4건은 모두 코퍼스에 관련 사례가 존재하지 않는 쟁점에서 발생하였다. 이는 Agent가 근거 없는 억지 답변을 생성하는 대신 '사람 판단 필요'로 종료하는 통제 방안(11장)이 실제로 작동함을 보여준다. 다만 해당 케이스들이 8회 반복을 모두 소진한 뒤에야 종료된 점은 비효율로, '재검색 후에도 관련 사례 0건이면 조기 기권'하는 규칙의 추가가 개선 과제로 확인되었다.

셋째, Human override로 기각된 사례는 정확도 불일치 사례와 일치한다. 대표적으로 음주운전 면책 질의에서 Agent가 키워드만 유사한 구상권 분쟁 사례를 인용하였으나 쟁점이 상이하여 심사역 판정에서 기각되었다(10.2 참조). 관련성 재검증(CRAG)이 표면적 키워드 유사성까지 완전히 걸러내지는 못함을 보여주는 사례로, 최종 결정을 사람에게 두는 HITL 설계가 이러한 잔여 오류의 안전망으로 기능함을 실측으로 확인하였다.

넷째, 동일 질의를 반복 실행할 경우 추천(DENY vs 추가검토 필요)과 인용 사례 구성이 실행마다 달라지는 비결정성이 관찰되었다. 참고자료 제공이라는 본 Agent의 역할 범위에서는 허용 가능한 수준이나, 판단 일관성 제고를 위한 프롬프트-온도 조정이 향후 과제다.

12.5 측정의 한계

본 실측은 (1) 작성자 본인이 심사역 역할을 대행한 자체 테스트이며, (2) 표본 규모(실행 40회, 배치 질의 15건)가 작고, (3) 정확도는 정식 골드셋이 아닌 표본 수동 판정 근사치라는 한계가 있다. 심사역 채택률·판단 정확도의 신뢰할 수 있는 측정은 정답 라벨링된 골드셋 구축과 실제 심사역 대상 파일럿 운영 이후 가능하다.

12.6 실측 기반 개선 및 재검증 — 보완점

12.4에서 확인된 비효율(코퍼스 무관 쟁점이 최대 반복 횟수를 모두 소진하며 재검색만 반복)을 해소하기 위해, '서로 다른 검색어로 3회 이상 검색하고 2회 이상 관련성 재검증을 시도했음에도 통과 사례가 누적 0건이며 웹 외부자료도 없으면 즉시 기권 종료'하는 규칙을 추가하였다. 이는 반복 상한(8회)을 줄이는 것이 아니라 진전 없음 상태를 감지하는 조건부 종료 규칙으로, LLM 재량 밖의 결정론적 가드레일로 구현되어 risk-hitl과 동일한 계열에 속한다. 근거를 찾아가는 정상 케이스는 통과 사례가 발생하는 순간 조건이 해제되므로 영향을 받지 않으며, 기권 후에도 HITL 승인 게이트는 동일하게 발동한다 — 생략되는 것은 사람 확인이 아니라 낭비되는 재검색이다.

개선 효과는 기권 케이스 4건(도수치료·신의료기술·정신질환·태아보험)을 재실행하여 검증하였다. 평균 latency는 14.4초에서 9.4초로 35% 감소하였고, 평균 입력 토큰은 20,313에서 10,129로, 케이스당 비용은 \$0.0033에서 \$0.0017로 각각 50% 감소하였다. 4건 모두 정확히 기권하였고 관련 사례가 있는 쟁점을 잘못 기권시키는 오발동은 없었다. 아울러 기권 문구도 '최대 반복 횟수 내에 결론을 내지 못했습니다'라는 수동적 실패 보고에서 '검색 N회·재검증 M회 시도, 통과 0건 — 조기 기권'이라는 근거를 명시한 능동적 판단으로 개선하였다. 임계값(검색 3회·재검증 2회)은 현 코퍼스 규모(160건)에서의 실측 관찰에 근거한 경험값으로, 코퍼스 확장 시 재조정이 필요하다.

13. 기대 효과와 한계

13.1 기대효과

- 애매한 청구 건에 대한 심사역의 판단 근거 탐색 시간 단축 (유사 판례를 수작업으로 찾는 대신 자동 검색·요약)
- 심사 판단의 일관성 제고: 유사 쟁점에 대한 과거 조정 결정 기준을 참고함으로써 심사역 간 판단 편차를 줄이는 데 기여할 잠재력
- 분쟁조정 신청으로 이어지기 전 단계에서 더 정교한 1차 판단을 지원함으로써, 장기적으로 분쟁조정 신청 건수 자체를 줄이는 데 기여할 가능성
- 감사로그 축적을 통해 향후 심사 기준의 표준화·문서화에 활용할 수 있는 데이터 자산 확보

13.2 한계

- 코퍼스 규모의 한계: 201건(보험 관련 160건) 규모는 실제 상용 서비스 대비 매우 작으며, 쟁점 유형별 표본이 적어 커버리지가 제한적이다.
- 실측의 한계: 12장의 실측치는 작성자 본인이 심사역 역할을 대행한 자체 테스트 기준 참고치이며, 표본 규모가 작아 실제 심사역 대상 파일럿에서의 재측정이 필요하다. 실측에서 확인된 기권 지연의 비효율은 조기 기권 가드레일로 구현·재검증을 완료하였으나(12.6), 임계값은 코퍼스 확장 시 재조정이 필요한 경험 값이다.
- 웹검색(web_search_tool) 통합은 신뢰 도메인 제한이 검색 결과의 정확성 자체를 보장하지는 않으며 실사용 검증은 아직 이루어지지 않았다.
- 현재 세션 상태 관리(LangGraph MemorySaver)는 메모리 기반으로, 프로세스 종료 시 상태가 유지되지 않는다. 단일 실행 내 HITL 처리에는 문제가 없으나, 다중 사용자 동시 처리나 장시간 대기가 필요한 웹 서비스로 확장할 경우 PostgreSQL 기반 checkpointer로 교체가 필요하다.
- 법적·조직적 과제: 실제 도입을 위해서는 심사 기준에 대한 내부 규정 정비, 책임소재에 대한 법무 검토, 감독당국과의 사전 협의 등 기술 외적인 절차가 별도로 필요하다.